

Projet Analyse de données

Contents

Importation des librairies et des données	2
Préparation des données	2
Analyse descriptive	3
Valeurs manquantes	3
Boxplots et Valeurs Aberrantes	3
Données Brutes	3
Données log-transformées	4
Données Centrées-Réduites	5
Analyse Unidimensionnelle	6
Variables quantitatives	6
Histogramme des variables quantitatives	7
Variables qualitatives	7
Barplots de nos variables qualitatives	7
Analyse Bidimensionnelle	8
Méthodes Factorielles	9
Analyse en Composantes Principales	9
Variance Expliquée	9
Graphe des individus	10
Graphe des variables	11
Analyse Factoriel Multiple	12
Discretisation des Variables	12
Application de la MCA	13
Graphes des modalités	13
Analyse Linéaire Discriminante	14
LDA pour le Type d'EPCI	15
Clustering	17
Kmeans	17
Détermination du nombre de classe k optimal	17
Clustering Hiérarchique	21
Détermination du nombre de classe k optimal	22
Modèle Linéaire et Modèle linéaire Généralisé	23
Régression linéaire Multiple : Gaz à effet de serre en fonction des polluants	23
Régression linéaire en incluant toutes les variables	23
Sélection de variables	24
Anova	26
Ancova	29

Importation des librairies et des données

On importe les librairies dont on aura besoin tout au long du projet.

Importons les données sous un le format DataFrame.

```
data = read.csv("./data/Data-projetmodIA-2324.csv")
data = as.data.frame(data)
```

Préparation des données

Jetons un premier coup d'œil à notre jeu de données.

```
str(data)
```

```
## 'data.frame':   984 obs. of  36 variables:
## $ code_epci      : int  200006930 200017341 200022986 200023620 200023737 200027183 200030435 ...
## $ lib_epci       : chr   "CC du Haut Allier" "CC Lodévois et Larzac" "CC du Grand Pic Saint-Loup" ...
## $ annee_inv      : int   2019 2019 2019 2019 2019 2019 2019 2019 2019 2019 ...
## $ nox_kg         : num   65634 310288 337656 298100 447187 ...
## $ so2_kg         : num   3867 8083 9373 4092 13650 ...
## $ pm10_kg        : num   15729 50929 143624 126736 143526 ...
## $ pm25_kg        : num   10976 38592 82144 63332 111854 ...
## $ co_kg          : num   173194 593037 1275977 780231 1386798 ...
## $ c6h6_kg        : num   2319 8349 18806 12250 21346 ...
## $ nh3_kg         : num   133686 114533 71177 244267 130427 ...
## $ ges_teqco2     : num   43995 127777 161137 116802 216302 ...
## $ ch4_t          : num    617 436 252 276 448 ...
## $ co2_t          : num   17832 93017 125005 79458 161748 ...
## $ n2o_t          : num    17.1 19.8 17.6 51 24.6 ...
## $ TypeEPCI       : chr   "CC" "CC" "CC" "CC" ...
## $ nomdepart      : chr   "Lozère" "Hérault" "Hérault" "Gers,Haute-Garonne" ...
## $ Ardèche        : int    0 0 0 0 0 0 0 0 0 0 ...
## $ Ariège         : int    0 0 0 0 0 0 0 0 0 0 ...
## $ Aude           : int    0 0 0 0 0 0 0 0 0 0 ...
## $ Aveyron        : int    0 0 0 0 0 0 0 0 0 0 ...
## $ Gard           : int    0 0 0 0 0 0 0 0 0 0 ...
## $ Haute.Garonne  : int    0 0 0 1 0 0 0 1 0 0 ...
## $ Gers           : int    0 0 0 1 0 0 1 0 0 0 ...
## $ Hérault        : int    0 1 1 0 0 0 0 0 0 0 ...
## $ Landes         : int    0 0 0 0 0 0 1 0 0 0 ...
## $ Lot            : int    0 0 0 0 1 0 0 0 0 0 ...
## $ Lot.et.Garonne : int    0 0 0 0 0 0 0 0 0 0 ...
## $ Lozère         : int    1 0 0 0 0 0 0 0 0 0 ...
## $ Pyrénées.Atlantiques: int    0 0 0 0 0 0 0 0 0 0 ...
## $ Hautes.Pyrénées : int    0 0 0 0 0 0 0 0 0 0 ...
## $ Pyrénées.Orientales : int    0 0 0 0 0 1 0 0 0 0 ...
## $ Tarn           : int    0 0 0 0 0 0 0 1 1 1 ...
## $ Tarn.et.Garonne : int    0 0 0 0 0 0 0 0 0 0 ...
## $ Vaucluse       : int    0 0 0 0 0 0 0 0 0 0 ...
## $ latit          : num   44.7 43.8 43.8 43.6 44.5 ...
## $ longit         : num    3.77 3.37 3.79 1.07 1.45 ...
```

On remarque que notre DataFrame se compose de 984 individus et de 36 variables. Récupérons les indices des variables qui sont qualitatives et de celles qui sont quantitatives.

```

nbcou = ncol(data)
nbligne = nrow(data)
ind_quan = c(4:14,nbcou-1,nbcou)
ind_qual = c(1:3,15:(nbcou-2))
ind_pol = c(4:14)

```

On transforme les variables qualitatives en facteurs à l'aide de la commande Factor.

```

for (ind in ind_qual){
  data[,ind] = as.factor(data[,ind])
}

```

De plus, nous remarquons que certaines variables sont en Kg et d'autres sont en Tonnes. Mettons les toutes en Tonnes pour une meilleure compréhension.

```

df=data
to_tonnes =c('nox_kg','so2_kg','pm10_kg','pm25_kg','co_kg','c6h6_kg','nh3_kg','ges_teqco2')
name_to_tonne=c('nox_t','so2_t','pm10_t','pm25_t','co_t','c6h6_t','nh3_t','ges_teqco2')
df[to_tonnes] = df[to_tonnes]/1000
colnames(df[to_tonnes]) = name_to_tonne
colnames(df)[c(4:11)] = name_to_tonne
df$ch4_t_lda = ifelse(df$ch4_t > 1000, "Above", "Below")
ind_qual = c(ind_qual , 37)

```

Analyse descriptive

Valeurs manquantes

Observons si notre jeu données possède des valeurs manquantes. La commande suivante nous montre que celui-ci n'en possède pas.

```
sum(is.na(df))
```

```
## [1] 0
```


Boxplots et Valeurs Aberrantes

Données Brutes

Pour détecter les valeurs aberrantes, traçons le boxplot des différentes variables.

```
boxplot(df[,ind_pol],main='Boxplot de nos variables quantitaives')
```

Boxplot de nos variables quantitatives




On remarque que la plupart des boxplots sont écrasés. La médiane pour chaque variable se situe autour de 0. On peut observer que de nombreux outliers sont présents pour la variable `co2_t`. De plus, celle-ci possède la plus grande variance. Effectuer une étude sur le jeu de données tel quel reviendrait donc à étudier uniquement la variable `co2_t` et nous perdriions donc beaucoup d'information.

Données log-transformées

Nous allons donc appliquer la fonction `log` pour pouvoir mieux observer nos variables.

```
df[,ind_pol]=log(df[,ind_pol])
boxplot(df[,ind_pol],main='Boxplot de nos variables quantitatives')
```


Boxplot de nos variables quantitatives



Données Centrées-Réduites

On remarque que les boxplots sont plus clairs et ont presque la même taille et donc les variables ont maintenant presque la même dispersion. Chaque variable possède quelques outliers. De plus, les données ayant la même unité, on va maintenant centrer les données.

```
df[,ind_pol] = scale(df[,ind_pol],center=TRUE,scale=TRUE)
boxplot(df[,ind_pol])
```



Les boxplots de nos données centrés ont à peu près la même forme. On remarque aussi la présence de quelques outliers. On a décidé donc d'enlever les outliers.


```
remove_outliers <- function(data_frame, columns) {  
  # Définir le facteur d'échelle interquartile (IQR)  
  iqr_factor <- 1.5  
  
  # Appliquer la règle des quantiles pour chaque colonne  
  for (col in columns) {  
    # Calculer les quantiles  
    q1 <- quantile(data_frame[[col]], 0.15)  
    q3 <- quantile(data_frame[[col]], 0.85)  
  
    # Calculer l'IQR  
    iqr <- q3 - q1  
  
    # Calculer les limites  
    lower_limit <- q1 - iqr_factor * iqr  
    upper_limit <- q3 + iqr_factor * iqr  
  
    # Supprimer les outliers  
    data_frame <- data_frame[data_frame[[col]] >= lower_limit & data_frame[[col]] <= upper_limit, ]  
  }  
  return(data_frame)  
}  
df = remove_outliers(df, colnames(df)[ind_pol])
```

Analyse Unidimensionnelle

Variables quantitatives

Afin de réaliser l'analyse des variables quantitatives, nous allons réaliser les histogrammes des différentes variables. Pour un souci d'espace, on ne va afficher que l'histogramme d'une seule variable.

```
#for (var in ind_pol) {  
for (var in ind_pol[6:6]) {  
  fd_binwidth <- (2 * IQR(df[, var])) / (length(df[, var])^(1/3))  
  
  # Création de l'histogramme avec ggplot2  
  p <- ggplot(df, aes_string(x = colnames(df)[var])) +  
    geom_histogram(binwidth = fd_binwidth, fill = "blue", color = "black", alpha = 0.5) +  
    labs(title = paste("Histogram of Variable", colnames(df)[var]),  
         x = colnames(df)[var], y = "Frequency")  
  
  # Forcer l'affichage du graphique  
  print(p)  
}
```



Histogramme des variables quantitatives

Nous observons que nos variables ont généralement bien une distribution gaussienne.

Variables qualitatives

Barplots de nos variables qualitatives Nous allons ici tracer les barplots de quelques variables qualitatives pour avoir une idée de la répartition des modalités.

Supposons que df soit votre DataFrame et qual_barplot contienne les indices des variables qualitatives
 qual_barplot <- c(3, 15, 16)

Sélectionner les colonnes qualitatives
 df_qual <- df[, qual_barplot]

Fonction pour générer un barplot pour une variable qualitative
 generate_barplot <- function(variable) {
 ggplot(df_qual, aes_string(x = colnames(df_qual)[variable])) +
 geom_bar(fill = "blue", color = "black", alpha = 0.7) +
 geom_text(stat = "count", aes(label = ..count..), vjust = -0.5, color = "black") + # Ajout des étiquettes
 labs(title = paste("Barplot of Variable", colnames(df_qual)[variable]),
 x = colnames(df_qual)[variable], y = "Count") +
 theme(axis.text.x = element_text(angle = 45, hjust = 1))
 }

Ajuster la taille de l'output
 options(repr.plot.width = 6, repr.plot.height = 4)


Afficher les barplots séparément
 for (i in seq_along(qual_barplot)) {
 print(generate_barplot(i))
 }

```
}
```

Nous remarquons donc que le nombre d'individu par année est homogènement réparti. La modalité CC de la variable TypeEPCI est la plus présente suivi par la modalité CA. Enfin, certains départements sont bien plus présents que d'autres notamment l'Aveyron, l'Hérault ou encore le Gers.

Analyse Bidimensionnelle

```
corrplot.mixed(round(cor(df[,ind_quan]),2),lower = 'ellipse',upper='number',bg = "black")
```



On peut observer que certains polluants sont très corrélés entre eux positivement par exemple `co_t` et `pm25_t`, `co_t` et `c6h6_t`, `co2_t` et `ges_teqco2`, `co2_t` et `nox_t`. Il est intéressant également de remarquer qu'aucun polluant n'est très corrélé négativement avec un autre.

Méthodes Factorielles

Analyse en Composantes Principales


Réalisons maintenant une ACP sur notre jeux de donnée.

```
acp_result <- PCA(df,quali.sup= ind_qual, graph = FALSE)
print(paste("Dim", 1:13, sep = "."))
```


```
## [1] "Dim.1" "Dim.2" "Dim.3" "Dim.4" "Dim.5" "Dim.6" "Dim.7" "Dim.8"
## [9] "Dim.9" "Dim.10" "Dim.11" "Dim.12" "Dim.13"
```

Variance Expliquée

```
barplot(acp_result$eig[,2], main="Variance expliquée (%)", names.arg=paste("Dim",1:nrow(acp_result$eig))
```



```
barplot(acp_result$eig[,3], main="Variance expliquée cumulée (%)", names.arg=paste("Dim",1:nrow(acp_result$eig))
abline(h=90,col='red')
```



Nous remarquons grâce à ces graphes qu'en gardant trois composantes principales, on conserve près de 90% de l'inertie ce qui est très bien.


Graphe des individus

```
gg_indiv1 <- ggplot(as.data.frame(acp_result$ind$coord), aes(x = Dim.1, y = Dim.2, colour = df$annee_in)) +
  geom_point(size = 1) +
  labs(title = "Graphe des individus dans le premier plan factoriel (Dim.1, Dim.2) avec la coloration s") +
  theme_minimal()


gg_indiv2 <- ggplot(as.data.frame(acp_result$ind$coord), aes(x = Dim.1, y = Dim.2, colour = df$TypeEPCI)) +
  geom_point(size = 1) +
  labs(title = "Graphe des individus dans le premier plan factoriel (Dim.1, Dim.2) avec la coloration s") +
  theme_minimal()

grid.arrange(gg_indiv1, gg_indiv2, nrow = 2)
```

Graphique des individus dans le premier plan factoriel (Dim.1, Dim.2) avec la coloration selon l'année d'observation



Graphique des individus dans le premier plan factoriel (Dim.1, Dim.2) avec la coloration selon le type d'EPCI



Le premier graphique représente les individus en fonction des deux premières composantes principales. Ils sont colorés par année. On peut observer que les années ne sont pas regroupées entre elles. Ainsi, pour une même année EPCI, on retrouve tous les niveaux de pollution.


Le second graphique représente les individus en fonction des deux premières composantes principales. Ils sont colorés par type d'EPCI. Une observation notable réside dans le regroupement des individus de même type d'EPCI. En effet, les EPCI de type **CC** (représentés par le bloc vert) se concentrent dans la partie gauche du graphique, suivis par les **CU**, puis les **CA** qui occupent la partie droite, et enfin les Métropoles qui se situent davantage à droite encore.

Des outliers (de type **CC**) sont présents dans la partie gauche des deux graphiques. On remarque que ces observations ont tous été enregistrées pour des dates différentes.

Graphique des variables

```
# Visualisation de la contribution des variables à la première et à la deuxième composante principale
f1 = fviz_pca_var(acp_result,
  choice = "var", # Afficher la contribution des variables
  axes = c(1, 2), # Axes à visualiser
  title = "Contribution des variables aux composantes principales (1 et 2)",
  repel = TRUE)   # Utiliser repel pour éviter le chevauchement des noms de variables

# Visualisation de la contribution des variables à la première et à la troisième composante principale
f2 = fviz_pca_var(acp_result,
  choice = "var", # Afficher la contribution des variables
  axes = c(1, 3), # Axes à visualiser
  title = "Contribution des variables aux composantes principales (1 et 3)",
  repel = TRUE)   # Utiliser repel pour éviter le chevauchement des noms de variables
grid.arrange(f1, f2, ncol = 2)
```



Nous pouvons analyser les composantes principales comme combinaison linéaire des différentes variables de façon suivante :

$$C1 = 0.9(pm10_t + ges_teqco2 + pm25_t + nox_t + c6h6_t + co_t + co2_t + so2_t)$$

$$C2 = 0.55latit + 0.7*(ch4_t + nh3_t + n2o_t) - 0.4longit$$

$$C3 = 0.6*latit + 0.8*long$$

La première composante représente donc le gaz à effet de serre ainsi que les polluants qui y contribuent.

La seconde composante représente donc le méthane, l'ammoniac, et le protoxyde d'azote.

Analyse Factoriel Multiple

Etant donné le fait que les deux modalités **Métropole** et **CU** ont un très faible effectif par rapport aux autres modalités, on a décidé quand même de recoder la variable **TypeEPCI** un peu après.

Discrétisation des Variables

Concernant la discrétisation des variables, deux choix se présentent pour nous:

- Soit on discrétise de façon à obtenir I intervalles de même longueur mais pas nécessairement de même effectifs pour chaque variable.
- Soit on utilise les quantiles de façon à obtenir I intervalles de même effectifs mais pas nécessairement de même longueur.

On a fait plutôt le premier choix. Toutefois, on a essayé de voir l'effectif de chaque intervalle pour s'assurer qu'il n'ait pas de modalité à faible effectif.

```
df_mca = df
alpha <- c(0, 1/3, 2/3, 1)
breaks = 3
labels = letters[1:breaks]
for (ind in ind_quan) {
```


```

col_name <- paste(colnames(df_mca)[ind], "")
#quantiles = quantile(df_mca[[colnames(df_mca)[ind]]],probs= alpha)
df_mca[[col_name]] <- cut(df_mca[[colnames(df_mca)[ind]]], breaks = breaks, labels =labels, include.lowest=TRUE)
}

ind_mca = c(15,16,37:49)
df_mca = df_mca[,ind_mca]

#for (ind in 1:ncol(df_mca)){
for (ind in 6:6){
  barplot(table(df_mca[[ind]]),main=colnames(df_mca)[ind])
}

```



Application de la MCA

```

# Appliquer la MCA
mca_result <- MCA(df_mca, graph = FALSE)

```

Graphes des modalités

```

plot(mca_result, axes = c(1, 2), choix = "ind", invisible = "ind", habillage = "quali", autoLab = "yes")

```



Analyse Linéaire Discriminante

```
lda_columns = c(ind_quan, 15, 3, 37)
df_lda = df[lda_columns]
```

```
lda_model_TypeEPCI <- lda(TypeEPCI ~., data = df_lda)
lda_predictions_TypeEPCI <- predict(lda_model_TypeEPCI)
```

```
library(ggplot2)
library(ggpubr)
```

```
# Création du dataframe avec les prédictions et les classes
df_plot <- data.frame(LD1 = lda_predictions_TypeEPCI$x[, 1],
```

```

LD2 = lda_predictions_TypeEPCI$x[, 2],
Classe = df_lda$TypeEPCI)

# Tracé du graphe avec ggplot2 et ajout d'ellipses
p <- ggplot(df_plot, aes(x = LD1, y = LD2, color = Classe)) +
  geom_point(size = 1) + # Réduire la taille des points
  labs(title = "Graphe des individus dans les axes LD1 et LD2",
        x = "LD1",
        y = "LD2",
        color = "Classe") +
  theme_minimal() +
  theme(legend.position = "right")

# Ajout d'ellipses de confiance
p + stat_ellipse(type = "norm", geom = "polygon", alpha = 0.2)

```



LDA pour le Type d'EPCI

```

coord_individus = lda_predictions_TypeEPCI$x
correlations_lda <- cor(df_lda[-c(14,15,16)], coord_individus)

Coord_ld1 = correlations_lda[,1]
Coord_ld2 = correlations_lda[,2]

variables_df <- data.frame(x = rep(0, length(Coord_ld1)),
  y = rep(0, length(Coord_ld2)),
  xend = Coord_ld1,
  yend = Coord_ld2,
  variable = names(Coord_ld1)) # Noms des variables


```

```

circle_df <- data.frame(x = cos(seq(0, 2 * pi, length.out = 100)),
                        y = sin(seq(0, 2 * pi, length.out = 100)))

ggplot() +
  geom_hline(yintercept = 0, linetype = "dashed", color = "gray") +
  geom_vline(xintercept = 0, linetype = "dashed", color = "gray") +
  geom_segment(data = variables_df, aes(x = x, y = y, xend = xend, yend = yend, color = variable),
              arrow = arrow(type = "closed", angle = 20, length = unit(0.2, "inches"))) +
  geom_text(data = variables_df, aes(x = xend, y = yend, label = variable, color = variable),
            hjust = 1.2, vjust = 1.2, size = 3) +
  geom_path(data = circle_df, aes(x, y), color = "black") +
  labs(title = "Cercle des Corrélations avec les dimenstions LD1 et LD2 de l'analyse linéaire discriminante",
       x = "Coordonnée LD1",
       y = "Coordonnée LD2",
       color = "Variable") +
  theme_minimal() +
  theme(legend.position = "right",
        axis.title = element_text(size = 12),
        axis.text = element_text(size = 10),
        legend.text = element_text(size = 10),
        legend.title = element_text(size = 12))

```



```

lda_model_ch4_t <- lda(ch4_t_lda~., data = df_lda)
lda_predictions_ch4_t <- predict(lda_model_ch4_t)

```


Clustering

Kmeans


```
df_kmeans = df[ind_quan]
```

Détermination du nombre de classe k optimal

```
Kmax<-15
reskmeanscl<-matrix(0,nrow=nrow(df_kmeans),ncol=Kmax-1)
lintra<-NULL
for (k in 2:Kmax){
  resaux<-kmeans(df_kmeans,centers = k)
  reskmeanscl[,k-1]<-resaux$cluster
  lintra<-c(lintra,resaux$tot.withinss)
}


df_intra<-data.frame(K=2:15,lintra=lintra)
ggplot(df_intra,aes(x=K,y=lintra))+geom_line()+geom_point(size=1)+xlab("Nombre de classes")+ylab("Inert.
```

L'évolution de l'inertie Intra classe en fonction du nombre de centres de clusters.



Intertie Intra-classe


```
library(cluster)
Silhou<-NULL
for (k in 2:Kmax){
  aux<-silhouette(reskmeanscl[,k-1],daisy(df_kmeans))
  Silhou<-c(Silhou,mean(aux[,3]))
}
df_silh<-data.frame(K=2:Kmax,Silhouette=Silhou)
ggplot(df_silh,aes(x=K,y=Silhouette))+
  geom_point()+
  geom_line()+theme(legend.position = "bottom")
```



Silhouette

```
aux<-silhouette(reskmeanscl[,5],daisy(df_kmeans))
fviz_silhouette(aux)+theme(plot.title = element_text(size =9))
```

##	cluster	size	ave.sil.width
## 1	1	62	0.33
## 2	2	192	0.28
## 3	3	175	0.31
## 4	4	109	0.21
## 5	5	230	0.26
## 6	6	191	0.20




```
rm(df_silh,Silhou,aux)
```

```
Kmax<-15
reskmeanscl<-matrix(0,nrow=nrow(df_kmeans),ncol=Kmax-1)
Calin<-NULL
for (k in 2:Kmax){
  resaux<-kmeans(df_kmeans,centers = k)
  reskmeanscl[,k-1]<-resaux$cluster
  Iintra = resaux$tot.withinss
  Iinter = resaux$betweenss
  coef = (Iinter/(k-1))/(Iintra/(nrow(df_kmeans)-k))
  Calin<-c(Calin,coef)
}

df_Calin<-data.frame(K=2:15,Calin_Coef=Calin)
ggplot(df_Calin,aes(x=K,y=Calin_Coef))+geom_line()+geom_point(size=1)+xlab("Nombre de classes")+ylab("Iinter/Iintra")
```

L'évolution du coefficient de Calinski-Harabsz en fonction du nombre de centres de clusters.




Calinski-Harabsz

```
reskmeans_def = kmeans(df_kmeans,centers = 4)
```

```
fviz_cluster(reskmeans_def,data=df_kmeans,axes=c(1,2),ellipse.type = "norm",labelsize = 8,geom=c("point"))
```

Cluster plot



```
adjustedRandIndex(reskmeans_def$cluster,df$TypeEPCI)
```

```
## [1] 0.1142881
```

Clustering Hiérarchique

```
df_hierarchique = df_kmeans
```

```
dist_matrix <- dist(df_hierarchique)
```

```
res_hc<- hclust(dist_matrix, method = "ward.D2")
```

```
str(res_hc)
```

```
## List of 7
```

```
## $ merge      : int [1:958, 1:2] -479 -493 -676 -736 -727 -642 -772 -731 -738 -205 ...
```

```
## $ height     : num [1:958] 0.0445 0.0492 0.0553 0.0559 0.0571 ...
```

```
## $ order      : int [1:959] 57 216 693 854 375 534 65 224 702 863 ...
```

```
## $ labels     : chr [1:959] "1" "2" "3" "4" ...
```

```
## $ method     : chr "ward.D2"
```

```
## $ call       : language hclust(d = dist_matrix, method = "ward.D2")
```


```
## $ dist.method: chr "euclidean"
```

```
## - attr(*, "class")= chr "hclust"
```

```
plot(res_hc, cex = 0.6, main = "Dendrogramme")
```

```
# Ajouter des labels aux branches du dendrogramme
```

```
rect.hclust(res_hc, k = 4, border = 2:5)
```



Détermination du nombre de classe k optimal

```
Kmax <- 15
lintra_hierarchical <- numeric(Kmax - 1)

for (k in 2:Kmax) {
  cutree_clusters <- cutree(res_hc, k)
  str(cutree_clusters)
  total_withinss <- 0
  for (i in 1:k) {
    cluster_points <- which(cutree_clusters == i)
    cluster_data <- df_kmeans[cluster_points, ]
    total_withinss <- total_withinss + sum(dist(cluster_data)^2)
  }

  lintra_hierarchical[k - 1] <- total_withinss
}
```


Intertie Intra-classe

```
## Named int [1:959] 1 1 1 2 2 2 1 2 1 1 ...
## - attr(*, "names")= chr [1:959] "1" "2" "3" "4" ...
## Named int [1:959] 1 1 1 2 2 2 1 2 3 3 ...
## - attr(*, "names")= chr [1:959] "1" "2" "3" "4" ...
## Named int [1:959] 1 1 1 2 2 3 1 2 4 4 ...
## - attr(*, "names")= chr [1:959] "1" "2" "3" "4" ...
## Named int [1:959] 1 1 1 2 2 3 1 2 4 5 ...
## - attr(*, "names")= chr [1:959] "1" "2" "3" "4" ...
## Named int [1:959] 1 2 2 3 3 4 1 3 5 6 ...
## - attr(*, "names")= chr [1:959] "1" "2" "3" "4" ...
## Named int [1:959] 1 2 2 3 3 4 1 3 5 6 ...
## - attr(*, "names")= chr [1:959] "1" "2" "3" "4" ...
## Named int [1:959] 1 2 2 3 3 4 1 3 5 6 ...
## - attr(*, "names")= chr [1:959] "1" "2" "3" "4" ...
## Named int [1:959] 1 2 2 3 3 4 1 3 5 6 ...
## - attr(*, "names")= chr [1:959] "1" "2" "3" "4" ...
## Named int [1:959] 1 2 2 3 3 4 1 3 5 6 ...
## - attr(*, "names")= chr [1:959] "1" "2" "3" "4" ...
## Named int [1:959] 1 2 2 3 3 4 1 3 5 6 ...
## - attr(*, "names")= chr [1:959] "1" "2" "3" "4" ...
## Named int [1:959] 1 2 2 3 3 4 1 3 5 6 ...
## - attr(*, "names")= chr [1:959] "1" "2" "3" "4" ...
## Named int [1:959] 1 2 2 3 3 4 5 3 6 7 ...
## - attr(*, "names")= chr [1:959] "1" "2" "3" "4" ...
## Named int [1:959] 1 2 2 3 3 4 5 3 6 7 ...
## - attr(*, "names")= chr [1:959] "1" "2" "3" "4" ...

df_intra_hierarchical <- data.frame(K = 2:15, lintra = lintra_hierarchical)

ggplot(df_intra_hierarchical, aes(x = K, y = lintra)) +
```

```
geom_line() +
geom_point(size = 1) +
xlab("Nombre de classes") +
ylab("Inertie intraclasse") +
labs(title = "L'évolution de l'inertie Intra classe en fonction du nombre de clusters pour le clustering hiérarchique.")
```



Modèle Linéaire et Modèle linéaire Généralisé

Régression linéaire Multiple : Gaz à effet de serre en fonction des polluants

```
ind_regmulti = c(4:14)
df_regmulti = df[,ind_regmulti]
```

Regression linéaire en incluant toutes les variables

```
mod_reg_multi = lm(ges_teqco2 ~ . , data = df_regmulti)
summary(mod_reg_multi)
```


```
##
## Call:
## lm(formula = ges_teqco2 ~ . , data = df_regmulti)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -0.55525 -0.09027 -0.01230  0.06137  0.88949
##
## Coefficients:
```

```
##           Estimate Std. Error t value Pr(>|t|)
## (Intercept) -0.008201  0.004786  -1.714 0.086926 .
## nox_t        0.267759  0.030125   8.888 < 2e-16 ***
## so2_t        0.036316  0.009534   3.809 0.000148 ***
## pm10_t       -0.271206  0.030295  -8.952 < 2e-16 ***
## pm25_t        0.157159  0.037777   4.160 3.47e-05 ***
## co_t         -0.009881  0.051616  -0.191 0.848228
## c6h6_t        0.001898  0.042850   0.044 0.964676
## nh3_t        -0.279798  0.029280  -9.556 < 2e-16 ***
## ch4_t         0.244085  0.012347  19.769 < 2e-16 ***
## co2_t         0.604444  0.031403  19.248 < 2e-16 ***
## n2o_t         0.393794  0.030976  12.713 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1479 on 948 degrees of freedom
## Multiple R-squared:  0.9715, Adjusted R-squared:  0.9712
## F-statistic: 3235 on 10 and 948 DF,  p-value: < 2.2e-16
```


Sélection de variables

```
library(leaps)
select = regsubsets(ges_teqco2 ~ . ,data =df_regmulti,nbest=1,nvmax=100,method="backward")


plot(select,scale="adjr2")
```



```
plot(select,scale="Cp")
```

```
plot(select,scale="bic")
```



```
modbest = lm(ges_teqco2 ~ nox_t + so2_t + pm10_t + pm25_t + +nh3_t + ch4_t + co2_t + n2o_t,data=df_regmulti)
summary(modbest)
```

```
##
## Call:
## lm(formula = ges_teqco2 ~ nox_t + so2_t + pm10_t + pm25_t + +nh3_t +
##     ch4_t + co2_t + n2o_t, data = df_regmulti)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
```

```
## -0.55691 -0.09026 -0.01221 0.06120 0.88841
##
## Coefficients:
##             Estimate Std. Error t value Pr(>|t|)
## (Intercept) -0.008231 0.004779 -1.722 0.085353 .
## nox_t        0.267936 0.030043 8.918 < 2e-16 ***
## so2_t        0.035929 0.009432 3.809 0.000148 ***
## pm10_t       -0.268185 0.028898 -9.280 < 2e-16 ***
## pm25_t       0.149764 0.027425 5.461 6.05e-08 ***
## nh3_t        -0.279065 0.029166 -9.568 < 2e-16 ***
## ch4_t        0.244695 0.012147 20.145 < 2e-16 ***
## co2_t        0.601351 0.027201 22.108 < 2e-16 ***
## n2o_t        0.392467 0.030509 12.864 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.1477 on 950 degrees of freedom
## Multiple R-squared: 0.9715, Adjusted R-squared: 0.9713
## F-statistic: 4052 on 8 and 950 DF, p-value: < 2.2e-16
```

```
anova(modbest,mod_reg_multi)
```

```
## Analysis of Variance Table
##
## Model 1: ges_teqco2 ~ nox_t + so2_t + pm10_t + pm25_t + +nh3_t + ch4_t +
##          co2_t + n2o_t
## Model 2: ges_teqco2 ~ nox_t + so2_t + pm10_t + pm25_t + co_t + c6h6_t +
##          nh3_t + ch4_t + co2_t + n2o_t
##   Res.Df    RSS Df Sum of Sq    F Pr(>F)
## 1      950 20.737
## 2      948 20.735  2 0.0024644 0.0563 0.9452
```

Anova

```
modeleanova<-lm(ges_teqco2~TypeEPCI*annee_inv,data = data)
modeleanovaadd<-lm(ges_teqco2~TypeEPCI+annee_inv,data = data)
summary(modeleanova)
```

```
##
## Call:
## lm(formula = ges_teqco2 ~ TypeEPCI * annee_inv, data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -865721 -66010 -33713  22247 1174580
##
## Coefficients:
##                                Estimate Std. Error t value Pr(>|t|)
## (Intercept)                   455581     40674  11.201 < 2e-16 ***
## TypeEPCICC                    -324794     43618  -7.446 2.13e-13 ***
## TypeEPCICU                     570140    190779   2.988 0.00288 **
## TypeEPCIMetropole             1690136    137933  12.253 < 2e-16 ***
## annee_inv2015                   11637     57522   0.202 0.83972
## annee_inv2016                   19942     57522   0.347 0.72890
## annee_inv2017                   21133     57522   0.367 0.71340
```

```
## annee_inv2018          21619      57522   0.376  0.70711
## annee_inv2019          22741      57522   0.395  0.69268
## TypeEPCICC:annee_inv2015    -9302      61686  -0.151  0.88017
## TypeEPCICU:annee_inv2015    -4335     269803  -0.016  0.98718
## TypeEPCIMetropole:annee_inv2015  59851     195067   0.307  0.75905
## TypeEPCICC:annee_inv2016   -14262      61686  -0.231  0.81721
## TypeEPCICU:annee_inv2016     5485     269803   0.020  0.98378
## TypeEPCIMetropole:annee_inv2016 104252     195067   0.534  0.59316
## TypeEPCICC:annee_inv2017   -14607      61686  -0.237  0.81286
## TypeEPCICU:annee_inv2017    11380     269803   0.042  0.96637
## TypeEPCIMetropole:annee_inv2017 136456     195067   0.700  0.48439
## TypeEPCICC:annee_inv2018   -15520      61686  -0.252  0.80141
## TypeEPCICU:annee_inv2018    -1062     269803  -0.004  0.99686
## TypeEPCIMetropole:annee_inv2018 146937     195067   0.753  0.45147
## TypeEPCICC:annee_inv2019   -18062      61686  -0.293  0.76973
## TypeEPCICU:annee_inv2019     9299     269803   0.034  0.97251
## TypeEPCIMetropole:annee_inv2019 165248     195067   0.847  0.39713
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 186400 on 960 degrees of freedom
## Multiple R-squared:  0.6717, Adjusted R-squared:  0.6638
## F-statistic: 85.39 on 23 and 960 DF,  p-value: < 2.2e-16
```

```
summary(modeleanovaadd)
```

```
##
## Call:
## lm(formula = ges_teqco2 ~ TypeEPCI + annee_inv, data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -934356  -66270  -33117   21993 1173725
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)      464523     21118  21.996 < 2e-16 ***
## TypeEPCICC       -336753     17683 -19.044 < 2e-16 ***
## TypeEPCICU        573601     77342   7.416 2.61e-13 ***
## TypeEPCIMetropole 1792260     55918  32.052 < 2e-16 ***
## annee_inv2015        4400      20440   0.215   0.830
## annee_inv2016         9072      20440   0.444   0.657
## annee_inv2017        10397      20440   0.509   0.611
## annee_inv2018        10156      20440   0.497   0.619
## annee_inv2019         9394      20440   0.460   0.646
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 185100 on 975 degrees of freedom
## Multiple R-squared:  0.6712, Adjusted R-squared:  0.6685
## F-statistic: 248.8 on 8 and 975 DF,  p-value: < 2.2e-16
```

```
anova(modeleanovaadd,modeleanova)
```

```
## Analysis of Variance Table
```

```
##
## Model 1: ges_teqco2 ~ TypeEPCI + annee_inv
## Model 2: ges_teqco2 ~ TypeEPCI * annee_inv
##   Res.Df      RSS Df Sum of Sq    F Pr(>F)
## 1     975 3.3402e+13
## 2     960 3.3353e+13 15 4.9752e+10 0.0955    1

modeleannee<-lm(ges_teqco2~annee_inv,data = data)
anova(modeleannee,modelanovaadd)

## Analysis of Variance Table
##
## Model 1: ges_teqco2 ~ annee_inv
## Model 2: ges_teqco2 ~ TypeEPCI + annee_inv
##   Res.Df      RSS Df Sum of Sq    F    Pr(>F)
## 1     978 1.0157e+14
## 2     975 3.3402e+13  3 6.8172e+13 663.31 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

modeletype<-lm(ges_teqco2~TypeEPCI,data = data)
anova(modeletype,modelanovaadd)

## Analysis of Variance Table
##
## Model 1: ges_teqco2 ~ TypeEPCI
## Model 2: ges_teqco2 ~ TypeEPCI + annee_inv
##   Res.Df      RSS Df Sum of Sq    F Pr(>F)
## 1     980 3.3417e+13
## 2     975 3.3402e+13  5 1.4261e+10 0.0833 0.9949

modelenull<-lm(ges_teqco2~1,data = data)
anova(modelenull,modeletype)

## Analysis of Variance Table
##
## Model 1: ges_teqco2 ~ 1
## Model 2: ges_teqco2 ~ TypeEPCI
##   Res.Df      RSS Df Sum of Sq    F    Pr(>F)
## 1     983 1.0159e+14
## 2     980 3.3417e+13  3 6.8172e+13 666.42 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1


summary(modeletype)

##
## Call:
## lm(formula = ges_teqco2 ~ TypeEPCI, data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -941592  -65718  -34335   23368  1176886
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    471760     16451  28.677 < 2e-16 ***
```

```
## TypeEPCICC      -336753      17641 -19.089 < 2e-16 ***
## TypeEPCICU       573601      77160   7.434 2.3e-13 ***
## TypeEPCIMetropole 1792260      55787  32.127 < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 184700 on 980 degrees of freedom
## Multiple R-squared:  0.6711, Adjusted R-squared:  0.6701
## F-statistic: 666.4 on 3 and 980 DF,  p-value: < 2.2e-16
```

```
attach(data)
```

```
interaction.plot(TypeEPCI,annee_inv,ges_teeco2,col=c(2,4),pch=c(18,24),main="Interaction plot entre le '")
```



Ancova

```
modeleancova<-lm(ch4_t~TypeEPCI*annee_inv*nh3_kg*co_kg,data = data)
modeleancovasansinter<-lm(ch4_t~TypeEPCI+annee_inv+nh3_kg+co_kg,data = data)
summary(modeleancova)
```

```
##
## Call:
## lm(formula = ch4_t ~ TypeEPCI * annee_inv * nh3_kg * co_kg, data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2114.31  -175.60    52.64   219.29  1265.73
##
## Coefficients: (30 not defined because of singularities)
##                                Estimate Std. Error t value
```

## (Intercept)	4.488e+02	4.834e+02	0.928
## TypeEPCICC	-3.406e+02	5.023e+02	-0.678
## TypeEPCICU	4.698e+02	6.787e+02	0.692
## TypeEPCIMetropole	2.717e+03	1.934e+03	1.405
## annee_inv2015	3.533e+00	6.643e+02	0.005
## annee_inv2016	5.992e+01	6.653e+02	0.090
## annee_inv2017	1.074e+02	6.718e+02	0.160
## annee_inv2018	8.189e+01	6.619e+02	0.124
## annee_inv2019	-2.382e+01	6.663e+02	-0.036
## nh3_kg	1.967e-03	2.155e-03	0.913
## co_kg	-1.191e-04	1.802e-04	-0.661
## TypeEPCICC:annee_inv2015	3.090e+01	6.916e+02	0.045
## TypeEPCICU:annee_inv2015	-8.361e+01	9.327e+02	-0.090
## TypeEPCIMetropole:annee_inv2015	-3.687e+05	6.107e+05	-0.604
## TypeEPCICC:annee_inv2016	-1.604e+01	6.926e+02	-0.023
## TypeEPCICU:annee_inv2016	-3.231e+01	9.430e+02	-0.034
## TypeEPCIMetropole:annee_inv2016	1.076e+03	3.287e+03	0.327
## TypeEPCICC:annee_inv2017	-3.316e+01	6.994e+02	-0.047
## TypeEPCICU:annee_inv2017	-7.328e+01	9.416e+02	-0.078
## TypeEPCIMetropole:annee_inv2017	2.339e+04	3.757e+04	0.622
## TypeEPCICC:annee_inv2018	3.334e+01	6.901e+02	0.048
## TypeEPCICU:annee_inv2018	-2.105e+02	9.388e+02	-0.224
## TypeEPCIMetropole:annee_inv2018	2.755e+02	2.021e+03	0.136
## TypeEPCICC:annee_inv2019	1.185e+02	6.941e+02	0.171
## TypeEPCICU:annee_inv2019	-3.550e+02	9.520e+02	-0.373
## TypeEPCIMetropole:annee_inv2019	2.981e+03	4.022e+03	0.741
## TypeEPCICC:nh3_kg	2.299e-03	2.183e-03	1.053
## TypeEPCICU:nh3_kg	NA	NA	NA
## TypeEPCIMetropole:nh3_kg	-5.556e-02	7.803e-02	-0.712
## annee_inv2015:nh3_kg	-3.666e-04	2.991e-03	-0.123
## annee_inv2016:nh3_kg	-9.337e-04	2.930e-03	-0.319
## annee_inv2017:nh3_kg	-1.302e-03	2.837e-03	-0.459
## annee_inv2018:nh3_kg	-1.386e-03	2.729e-03	-0.508
## annee_inv2019:nh3_kg	-1.139e-03	2.778e-03	-0.410
## TypeEPCICC:co_kg	-2.071e-04	2.405e-04	-0.861
## TypeEPCICU:co_kg	NA	NA	NA
## TypeEPCIMetropole:co_kg	7.638e-04	1.217e-03	0.628
## annee_inv2015:co_kg	1.150e-05	2.445e-04	0.047
## annee_inv2016:co_kg	-5.946e-06	2.420e-04	-0.025
## annee_inv2017:co_kg	-2.822e-05	2.536e-04	-0.111
## annee_inv2018:co_kg	-7.539e-06	2.535e-04	-0.030
## annee_inv2019:co_kg	3.883e-05	2.584e-04	0.150
## nh3_kg:co_kg	2.362e-10	7.196e-10	0.328
## TypeEPCICC:annee_inv2015:nh3_kg	2.149e-04	3.030e-03	0.071
## TypeEPCICU:annee_inv2015:nh3_kg	NA	NA	NA
## TypeEPCIMetropole:annee_inv2015:nh3_kg	1.895e+00	3.137e+00	0.604
## TypeEPCICC:annee_inv2016:nh3_kg	7.481e-04	2.970e-03	0.252
## TypeEPCICU:annee_inv2016:nh3_kg	NA	NA	NA
## TypeEPCIMetropole:annee_inv2016:nh3_kg	-5.017e-03	1.916e-02	-0.262
## TypeEPCICC:annee_inv2017:nh3_kg	8.010e-04	2.876e-03	0.278
## TypeEPCICU:annee_inv2017:nh3_kg	NA	NA	NA
## TypeEPCIMetropole:annee_inv2017:nh3_kg	-9.138e-02	1.502e-01	-0.608
## TypeEPCICC:annee_inv2018:nh3_kg	6.263e-04	2.770e-03	0.226
## TypeEPCICU:annee_inv2018:nh3_kg	NA	NA	NA

## TypeEPCIMetropole:annee_inv2018:nh3_kg	1.332e-02	2.658e-02	0.501
## TypeEPCICC:annee_inv2019:nh3_kg	4.989e-04	2.817e-03	0.177
## TypeEPCICU:annee_inv2019:nh3_kg	NA	NA	NA
## TypeEPCIMetropole:annee_inv2019:nh3_kg	NA	NA	NA
## TypeEPCICC:annee_inv2015:co_kg	-5.607e-05	3.322e-04	-0.169
## TypeEPCICU:annee_inv2015:co_kg	NA	NA	NA
## TypeEPCIMetropole:annee_inv2015:co_kg	NA	NA	NA
## TypeEPCICC:annee_inv2016:co_kg	-7.816e-05	3.275e-04	-0.239
## TypeEPCICU:annee_inv2016:co_kg	NA	NA	NA
## TypeEPCIMetropole:annee_inv2016:co_kg	NA	NA	NA
## TypeEPCICC:annee_inv2017:co_kg	-1.015e-04	3.418e-04	-0.297
## TypeEPCICU:annee_inv2017:co_kg	NA	NA	NA
## TypeEPCIMetropole:annee_inv2017:co_kg	NA	NA	NA
## TypeEPCICC:annee_inv2018:co_kg	-1.944e-04	3.465e-04	-0.561
## TypeEPCICU:annee_inv2018:co_kg	NA	NA	NA
## TypeEPCIMetropole:annee_inv2018:co_kg	NA	NA	NA
## TypeEPCICC:annee_inv2019:co_kg	-2.364e-04	3.501e-04	-0.675
## TypeEPCICU:annee_inv2019:co_kg	NA	NA	NA
## TypeEPCIMetropole:annee_inv2019:co_kg	NA	NA	NA
## TypeEPCICC:nh3_kg:co_kg	-1.235e-10	7.749e-10	-0.159
## TypeEPCICU:nh3_kg:co_kg	NA	NA	NA
## TypeEPCIMetropole:nh3_kg:co_kg	NA	NA	NA
## annee_inv2015:nh3_kg:co_kg	5.951e-11	9.958e-10	0.060
## annee_inv2016:nh3_kg:co_kg	1.810e-10	9.546e-10	0.190
## annee_inv2017:nh3_kg:co_kg	2.332e-10	9.580e-10	0.243
## annee_inv2018:nh3_kg:co_kg	1.798e-10	9.261e-10	0.194
## annee_inv2019:nh3_kg:co_kg	8.796e-11	9.470e-10	0.093
## TypeEPCICC:annee_inv2015:nh3_kg:co_kg	2.278e-11	1.073e-09	0.021
## TypeEPCICU:annee_inv2015:nh3_kg:co_kg	NA	NA	NA
## TypeEPCIMetropole:annee_inv2015:nh3_kg:co_kg	NA	NA	NA
## TypeEPCICC:annee_inv2016:nh3_kg:co_kg	-8.920e-11	1.034e-09	-0.086
## TypeEPCICU:annee_inv2016:nh3_kg:co_kg	NA	NA	NA
## TypeEPCIMetropole:annee_inv2016:nh3_kg:co_kg	NA	NA	NA
## TypeEPCICC:annee_inv2017:nh3_kg:co_kg	-3.567e-11	1.036e-09	-0.034
## TypeEPCICU:annee_inv2017:nh3_kg:co_kg	NA	NA	NA
## TypeEPCIMetropole:annee_inv2017:nh3_kg:co_kg	NA	NA	NA
## TypeEPCICC:annee_inv2018:nh3_kg:co_kg	6.931e-11	1.008e-09	0.069
## TypeEPCICU:annee_inv2018:nh3_kg:co_kg	NA	NA	NA
## TypeEPCIMetropole:annee_inv2018:nh3_kg:co_kg	NA	NA	NA
## TypeEPCICC:annee_inv2019:nh3_kg:co_kg	9.967e-11	1.026e-09	0.097
## TypeEPCICU:annee_inv2019:nh3_kg:co_kg	NA	NA	NA
## TypeEPCIMetropole:annee_inv2019:nh3_kg:co_kg	NA	NA	NA
##	Pr(> t)		
## (Intercept)	0.353		
## TypeEPCICC	0.498		
## TypeEPCICU	0.489		
## TypeEPCIMetropole	0.160		
## annee_inv2015	0.996		
## annee_inv2016	0.928		
## annee_inv2017	0.873		
## annee_inv2018	0.902		
## annee_inv2019	0.971		
## nh3_kg	0.362		
## co_kg	0.509		

## TypeEPCICC:annee_inv2015	0.964
## TypeEPCICU:annee_inv2015	0.929
## TypeEPCIMetropole:annee_inv2015	0.546
## TypeEPCICC:annee_inv2016	0.982
## TypeEPCICU:annee_inv2016	0.973
## TypeEPCIMetropole:annee_inv2016	0.744
## TypeEPCICC:annee_inv2017	0.962
## TypeEPCICU:annee_inv2017	0.938
## TypeEPCIMetropole:annee_inv2017	0.534
## TypeEPCICC:annee_inv2018	0.961
## TypeEPCICU:annee_inv2018	0.823
## TypeEPCIMetropole:annee_inv2018	0.892
## TypeEPCICC:annee_inv2019	0.865
## TypeEPCICU:annee_inv2019	0.709
## TypeEPCIMetropole:annee_inv2019	0.459
## TypeEPCICC:nh3_kg	0.293
## TypeEPCICU:nh3_kg	NA
## TypeEPCIMetropole:nh3_kg	0.477
## annee_inv2015:nh3_kg	0.902
## annee_inv2016:nh3_kg	0.750
## annee_inv2017:nh3_kg	0.646
## annee_inv2018:nh3_kg	0.612
## annee_inv2019:nh3_kg	0.682
## TypeEPCICC:co_kg	0.389
## TypeEPCICU:co_kg	NA
## TypeEPCIMetropole:co_kg	0.530
## annee_inv2015:co_kg	0.962
## annee_inv2016:co_kg	0.980
## annee_inv2017:co_kg	0.911
## annee_inv2018:co_kg	0.976
## annee_inv2019:co_kg	0.881
## nh3_kg:co_kg	0.743
## TypeEPCICC:annee_inv2015:nh3_kg	0.943
## TypeEPCICU:annee_inv2015:nh3_kg	NA
## TypeEPCIMetropole:annee_inv2015:nh3_kg	0.546
## TypeEPCICC:annee_inv2016:nh3_kg	0.801
## TypeEPCICU:annee_inv2016:nh3_kg	NA
## TypeEPCIMetropole:annee_inv2016:nh3_kg	0.794
## TypeEPCICC:annee_inv2017:nh3_kg	0.781
## TypeEPCICU:annee_inv2017:nh3_kg	NA
## TypeEPCIMetropole:annee_inv2017:nh3_kg	0.543
## TypeEPCICC:annee_inv2018:nh3_kg	0.821
## TypeEPCICU:annee_inv2018:nh3_kg	NA
## TypeEPCIMetropole:annee_inv2018:nh3_kg	0.616
## TypeEPCICC:annee_inv2019:nh3_kg	0.859
## TypeEPCICU:annee_inv2019:nh3_kg	NA
## TypeEPCIMetropole:annee_inv2019:nh3_kg	NA
## TypeEPCICC:annee_inv2015:co_kg	0.866
## TypeEPCICU:annee_inv2015:co_kg	NA
## TypeEPCIMetropole:annee_inv2015:co_kg	NA
## TypeEPCICC:annee_inv2016:co_kg	0.811
## TypeEPCICU:annee_inv2016:co_kg	NA
## TypeEPCIMetropole:annee_inv2016:co_kg	NA
## TypeEPCICC:annee_inv2017:co_kg	0.767


```
## TypeEPCICU:annee_inv2017:co_kg NA
## TypeEPCIMetropole:annee_inv2017:co_kg NA
## TypeEPCICC:annee_inv2018:co_kg 0.575
## TypeEPCICU:annee_inv2018:co_kg NA
## TypeEPCIMetropole:annee_inv2018:co_kg NA
## TypeEPCICC:annee_inv2019:co_kg 0.500
## TypeEPCICU:annee_inv2019:co_kg NA
## TypeEPCIMetropole:annee_inv2019:co_kg NA
## TypeEPCICC:nh3_kg:co_kg 0.873
## TypeEPCICU:nh3_kg:co_kg NA
## TypeEPCIMetropole:nh3_kg:co_kg NA
## annee_inv2015:nh3_kg:co_kg 0.952
## annee_inv2016:nh3_kg:co_kg 0.850
## annee_inv2017:nh3_kg:co_kg 0.808
## annee_inv2018:nh3_kg:co_kg 0.846
## annee_inv2019:nh3_kg:co_kg 0.926
## TypeEPCICC:annee_inv2015:nh3_kg:co_kg 0.983
## TypeEPCICU:annee_inv2015:nh3_kg:co_kg NA
## TypeEPCIMetropole:annee_inv2015:nh3_kg:co_kg NA
## TypeEPCICC:annee_inv2016:nh3_kg:co_kg 0.931
## TypeEPCICU:annee_inv2016:nh3_kg:co_kg NA
## TypeEPCIMetropole:annee_inv2016:nh3_kg:co_kg NA
## TypeEPCICC:annee_inv2017:nh3_kg:co_kg 0.973
## TypeEPCICU:annee_inv2017:nh3_kg:co_kg NA
## TypeEPCIMetropole:annee_inv2017:nh3_kg:co_kg NA
## TypeEPCICC:annee_inv2018:nh3_kg:co_kg 0.945
## TypeEPCICU:annee_inv2018:nh3_kg:co_kg NA
## TypeEPCIMetropole:annee_inv2018:nh3_kg:co_kg NA
## TypeEPCICC:annee_inv2019:nh3_kg:co_kg 0.923
## TypeEPCICU:annee_inv2019:nh3_kg:co_kg NA
## TypeEPCIMetropole:annee_inv2019:nh3_kg:co_kg NA
##
## Residual standard error: 493.2 on 918 degrees of freedom
## Multiple R-squared: 0.7729, Adjusted R-squared: 0.7568
## F-statistic: 48.06 on 65 and 918 DF, p-value: < 2.2e-16
```

```
anova(modeleancovasansinter,modeleancova)
```

```
## Analysis of Variance Table
```

```
##
```

```
## Model 1: ch4_t ~ TypeEPCI + annee_inv + nh3_kg + co_kg
```

```
## Model 2: ch4_t ~ TypeEPCI * annee_inv * nh3_kg * co_kg
```

```
## Res.Df RSS Df Sum of Sq F Pr(>F)
```

```
## 1 973 253142933
```

```
## 2 918 223341999 55 29800933 2.2271 1.599e-06 ***
```

```
## ---
```

```
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
modeleancovasanstypeinter<-lm(ch4_t~TypeEPCI+annee_inv*nh3_kg*co_kg,data = data)
```

```
modeleancovasansanneeinter<-lm(ch4_t~annee_inv+TypeEPCI*nh3_kg*co_kg,data = data)
```

```
modeleancovasanscointer<-lm(ch4_t~co_kg+TypeEPCI*annee_inv*nh3_kg,data = data)
```

```
modeleancovasansnh3inter<-lm(ch4_t~nh3_kg+TypeEPCI*annee_inv*co_kg,data = data)
```

```
anova(modeleancovasanstypeinter,modeleancova)
```

```
## Analysis of Variance Table
```

```
##
## Model 1: ch4_t ~ TypeEPCI + annee_inv * nh3_kg * co_kg
## Model 2: ch4_t ~ TypeEPCI * annee_inv * nh3_kg * co_kg
##   Res.Df      RSS Df Sum of Sq      F    Pr(>F)
## 1      957 243553424
## 2      918 223341999 39  20211425 2.1301 8.772e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

anova(modeleancovasansanneeinter,modeleancova)

## Analysis of Variance Table
##
## Model 1: ch4_t ~ annee_inv + TypeEPCI * nh3_kg * co_kg
## Model 2: ch4_t ~ TypeEPCI * annee_inv * nh3_kg * co_kg
##   Res.Df      RSS Df Sum of Sq      F Pr(>F)
## 1      963 227344224
## 2      918 223341999 45   4002224 0.3656      1

anova(modeleancovasanscointer,modeleancova)

## Analysis of Variance Table
##
## Model 1: ch4_t ~ co_kg + TypeEPCI * annee_inv * nh3_kg
## Model 2: ch4_t ~ TypeEPCI * annee_inv * nh3_kg * co_kg
##   Res.Df      RSS Df Sum of Sq      F    Pr(>F)
## 1      941 231425237
## 2      918 223341999 23   8083238 1.4445 0.08092 .
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

anova(modeleancovasansnh3inter,modeleancova)

## Analysis of Variance Table
##
## Model 1: ch4_t ~ nh3_kg + TypeEPCI * annee_inv * co_kg
## Model 2: ch4_t ~ TypeEPCI * annee_inv * nh3_kg * co_kg
##   Res.Df      RSS Df Sum of Sq      F    Pr(>F)
## 1      941 249044240
## 2      918 223341999 23  25702241 4.5932 8.996e-12 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

modeleancovasansannee_typeinter<-lm(ch4_t~annee_inv+TypeEPCI+nh3_kg*co_kg,data = data)
modeleancovasansannee_nh3inter<-lm(ch4_t~annee_inv+nh3_kg+TypeEPCI*co_kg,data = data)
modeleancovasansannee_cointer<-lm(ch4_t~annee_inv+co_kg+nh3_kg*TypeEPCI,data = data)
anova(modeleancovasansanneeinter,modeleancovasansannee_typeinter)

## Analysis of Variance Table
##
## Model 1: ch4_t ~ annee_inv + TypeEPCI * nh3_kg * co_kg
## Model 2: ch4_t ~ annee_inv + TypeEPCI + nh3_kg * co_kg
##   Res.Df      RSS Df Sum of Sq      F    Pr(>F)
## 1      963 227344224
## 2      972 247098835 -9 -19754611 9.2975 1.268e-13 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
anova(modeleancovasansanneeinter,modeleancovasansannee_nh3inter)
```

```
## Analysis of Variance Table
##
## Model 1: ch4_t ~ annee_inv + TypeEPCI * nh3_kg * co_kg
## Model 2: ch4_t ~ annee_inv + nh3_kg + TypeEPCI * co_kg
##   Res.Df      RSS Df Sum of Sq    F    Pr(>F)
## 1      963 227344224
## 2      970 250786761 -7 -23442537 14.186 < 2.2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
anova(modeleancovasansanneeinter,modeleancovasansannee_cointer)
```

```
## Analysis of Variance Table
##
## Model 1: ch4_t ~ annee_inv + TypeEPCI * nh3_kg * co_kg
## Model 2: ch4_t ~ annee_inv + co_kg + nh3_kg * TypeEPCI
##   Res.Df      RSS Df Sum of Sq    F    Pr(>F)
## 1      963 227344224
## 2      970 235709606 -7 -8365382 5.0621 1.174e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
modeleancovasansannee<-lm(ch4_t~TypeEPCI*nh3_kg*co_kg,data = data)
anova(modeleancovasansannee,modeleancovasansanneeinter)
```

```
## Analysis of Variance Table
##
## Model 1: ch4_t ~ TypeEPCI * nh3_kg * co_kg
## Model 2: ch4_t ~ annee_inv + TypeEPCI * nh3_kg * co_kg
##   Res.Df      RSS Df Sum of Sq    F    Pr(>F)
## 1      968 232050078
## 2      963 227344224  5   4705854 3.9867 0.001386 **
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
summary(modeleancovasansanneeinter)
```

```
##
## Call:
## lm(formula = ch4_t ~ annee_inv + TypeEPCI * nh3_kg * co_kg, data = data)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -2266.74  -187.43    58.07   241.54  1194.80
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)    6.011e+02  1.860e+02   3.232 0.001272 **
## annee_inv2015  -1.651e+01  5.375e+01  -0.307 0.758746
## annee_inv2016  -4.506e+01  5.373e+01  -0.839 0.401896
## annee_inv2017  -1.070e+02  5.392e+01  -1.984 0.047522 *
## annee_inv2018  -1.741e+02  5.394e+01  -3.228 0.001289 **
## annee_inv2019  -1.708e+02  5.391e+01  -3.169 0.001577 **
## TypeEPCICC      -3.484e+02  1.909e+02  -1.825 0.068261 .
```

```

## TypeEPCICU -2.877e+03 7.565e+04 -0.038 0.969671
## TypeEPCIMetropole 2.941e+03 3.029e+03 0.971 0.331750
## nh3_kg 9.601e-04 7.504e-04 1.280 0.201025
## co_kg -1.278e-04 6.883e-05 -1.857 0.063575 .
## TypeEPCICC:nh3_kg 2.919e-03 7.619e-04 3.831 0.000136 ***
## TypeEPCICU:nh3_kg 2.167e-02 7.153e-01 0.030 0.975841
## TypeEPCIMetropole:nh3_kg -1.028e-02 1.672e-02 -0.615 0.539023
## TypeEPCICC:co_kg -3.027e-04 9.500e-05 -3.186 0.001487 **
## TypeEPCICU:co_kg 5.675e-04 1.337e-02 0.042 0.966151
## TypeEPCIMetropole:co_kg -1.908e-04 3.929e-04 -0.486 0.627298
## nh3_kg:co_kg 4.007e-10 2.534e-10 1.581 0.114125
## TypeEPCICC:nh3_kg:co_kg -1.552e-10 2.764e-10 -0.561 0.574625
## TypeEPCICU:nh3_kg:co_kg -3.789e-09 1.272e-07 -0.030 0.976242
## TypeEPCIMetropole:nh3_kg:co_kg 7.948e-10 1.973e-09 0.403 0.687207
## ---
## Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 485.9 on 963 degrees of freedom
## Multiple R-squared: 0.7688, Adjusted R-squared: 0.764
## F-statistic: 160.1 on 20 and 963 DF, p-value: < 2.2e-16

data <- transform(data, mh4_1000 = ifelse(ch4_t >= 1000, 1, 0))
glm_mh4<-glm(mh4_1000~TypeEPCI*annee_inv*nh3_kg*co_kg,data=data,family=binomial(link="logit"))
glm_mh4_sans_inter<-glm(mh4_1000~TypeEPCI+annee_inv+nh3_kg+co_kg,data=data,family=binomial(link="logit"))
anova(glm_mh4_sans_inter,glm_mh4,test="Chisq")

## Analysis of Deviance Table
##
## Model 1: mh4_1000 ~ TypeEPCI + annee_inv + nh3_kg + co_kg
## Model 2: mh4_1000 ~ TypeEPCI * annee_inv * nh3_kg * co_kg
## Resid. Df Resid. Dev Df Deviance Pr(>Chi)
## 1 973 740.05
## 2 918 692.87 55 47.177 0.7643

library(MASS)
stepAIC(glm_mh4_sans_inter, direction=c("backward"),p=4,trace=0) # AIC

##
## Call: glm(formula = mh4_1000 ~ TypeEPCI + nh3_kg + co_kg, family = binomial(link = "logit"),
## data = data)
##
## Coefficients:
## (Intercept) TypeEPCICC TypeEPCICU TypeEPCIMetropole
## -2.366e+00 -3.787e-01 -8.285e+00 7.819e+00
## nh3_kg co_kg
## 9.631e-06 -1.057e-06
##
## Degrees of Freedom: 983 Total (i.e. Null); 978 Residual
## Null Deviance: 1202
## Residual Deviance: 746.3 AIC: 758.3

```